

Extreme value Theory - Théorie des valeurs extrêmes

* Étudier les événements extrêmes / rares et prédire des quantiles

exemple : - estimer la proba d'une inondation qui survient tous les 100 ans

- en finance, estimer la VAR et sa proba de survenue.

$$\{ \text{VAR} = \inf \{ x \in \mathbb{R} : F_L(x) \geq \alpha \} \}$$

Il existe trois approches d'études des valeurs extrêmes

L'approche par blocs (Block maxima)

- $(X_i)_{i=1, \dots, m}$ des v.a.r iid.

- $M_m = \max(X_1, \dots, X_m)$

- $M_m^{(k)} = \max(X_1, \dots, X_m)$ le max de (X_i) dans le bloc (k)

Théorème de Fisher

si il existe $a_m > 0, m \geq 1$ et $\{b_m \in \mathbb{R}, m \geq 1\}$ tq

$$P\left(\frac{M_m - b_m}{a_m} \leq x\right) \xrightarrow{m \rightarrow \infty} H(x)$$

alors, $H(x) = \exp\left\{-\left(1 + \varepsilon \frac{x - \mu}{\sigma}\right)^{-1/\varepsilon}\right\}, 1 + \varepsilon \frac{x - \mu}{\sigma} > 0$

ou

$$= \exp\left\{-\exp\left(-\frac{x - \mu}{\sigma}\right)\right\}, \varepsilon = 0, x \in \mathbb{R}$$

* μ est le param de position (valeur type de (X_i))

* ε est le param de forme (agit sur la variance & la position)

* σ est le param d'échelle (agit sur la variance)

$\Rightarrow X$ suit donc une GEV $(\mu, \sigma, \varepsilon)$
(Generalized Extreme value)

Pour déterminer les constantes qui assure la limite vers une GEV (si elle existe), on fait appel aux conditions de Von Mises qui nécessitent initialement des connaissances sur le loi de X .

En pratique, on ajuste directement le modèle par maximum de vraisemblance, méthode des moments ou vraisemblance profilée.

$$\left[\begin{array}{l} \text{Conditions de Von Mises.} \\ \text{Mills ratio : } r(x) = (1 - F(x)) / f(x) \\ b_m = F^{-1}\left(1 - \frac{1}{m}\right), \quad a_m = r(b_m), \quad \varepsilon = \lim_{x \rightarrow x_+} r'(x) \end{array} \right]$$

1/ Période de retour et niveau de retour

Il peut être intéressant d'estimer un quantile d'une GEV(μ, σ, ε) pour déterminer la valeur à partir de laquelle X dépasse cette valeur avec proba p .
($F(y_p) = 1 - p \Leftrightarrow p = 1 - F(y_p)$)


$$\begin{aligned} y_p &= \mu - \sigma \frac{1 - 1 - \log(1 - p) \varepsilon}{\varepsilon} \\ &\text{niveau de retour} \quad \varepsilon \quad \text{(utilisé pour prediction)} \\ &\text{associé à un période } 1/p. \end{aligned}$$

(en finance, y_p est la VaR)


Interprétation

- y_p est en moyenne dépassé une fois tous les $1/p$ blocs (saisonnalité)
- Dans un bloc, la proba que y_p soit dépassé est $1/p$.


2/ Vérification de la qualité du modèle



* PP-plot :



+ return level / return period



En pratique, les logiciels
representent $-\frac{1}{\log(1-1/T)}$
 $\frac{x}{T} \rightarrow +\infty$

+ Convergence de la méthode d'optimisation

[penser au test de Wald et test de rapport
de vraisemblance (puissant) pour simplifier le modèle
[annuler certains param ou étudier ...]

3/ Tester l'incertitude des estimations


L'intervalle de confiance permet de savoir les
valeurs possibles prises par un estimateur

IC (symétrique) de Wald :

$$\hat{\theta} \pm z_{1-(1-\alpha)/2} \times \hat{\sigma}(\hat{\theta})$$

↑ erreur type

Il est qq fois utile de construire des IC non
symétriques pour savoir vers quelle borne
tend le paramètre d'intérêt. on utilise le
vraisemblance profile.



4. Reparamétrisation

Il est parfois utile de reparamétriser la loi $GEV(y_p, \sigma, \epsilon)$. De fait,

$$y_p = y_p + \sigma \frac{1 - (1 - \log(1-p))^{-\epsilon}}{\epsilon}$$

→ Cela permet d'avoir un IC pour le quantile
→ change la valeur typique prise par la distribution.

?? intérêt

II- L'approche par excès de seuil (peak over threshold - Threshold exceedances)

On étudie dans ce cas les valeurs qui excèdent un certain seuil.

Théorème de

Si X converge vers une GEV, alors

$$P(X > u_m(1+x) | X > u_m(x)) \xrightarrow{m \rightarrow \infty} 1 - \tilde{H}(x)$$

suite croissante \nearrow

avec $u_m(x) = a_m x + b_m, x \in \mathbb{R}_+.$

$$\tilde{H}(x) = \begin{cases} 1 - (1 + \epsilon x / \tau)^{-1/\epsilon}, & \epsilon \neq 0 \\ 1 - \exp(-x/\tau), & \epsilon = 0 \end{cases}$$

où τ est le nouveau paramètre d'échelle
 $\tau = \sigma + \epsilon(u - \mu)$

On dit que $\tilde{H}(\cdot)$ est une GPD(τ, ϵ), Generalized Pareto Distribution.

1. Le choix du seuil u .

!! on choisit u , on ne l'estime pas

Il est habituel que $u = \bar{F}(0,95)$, cependant, on peut utiliser des méthodes permettant d'avoir une idée sur le u optimal.

(!!) attention au compromis biais (u bas), variance (u élevé)

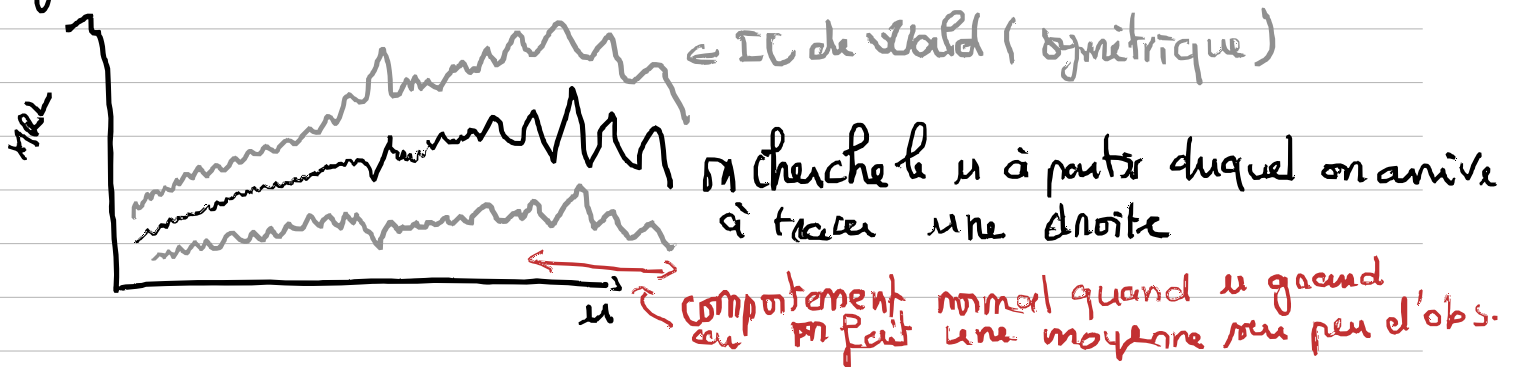
$$\left\{ \begin{array}{l} \text{Soit } X - u_0 | X > u_0 \sim \text{GPD}(\tau, \epsilon), \text{ alors } \forall u \geq u_0 \\ X - u | X > u \sim \text{GPD}(\bar{\tau}, \epsilon), \bar{\tau} = \tau + \epsilon(u - u_0) \end{array} \right.$$

↳ lorsque u est bien sélectionné, lorsqu'on augmente le seuil, la loi conditionnelle suit toujours une GPD avec une modification de paramètre d'échelle.

a) approche MRL

Si $X - u_0 | X > u_0 \sim \text{GPD}(\tau, \epsilon)$, $\epsilon < 1$, alors $\forall u \geq u_0$,

$\text{MRL}(u) = E(X - u | X > u) = \frac{\tau(u_0) + \epsilon u}{1 - \epsilon}$ est une fonction linéaire de u .




b) approche "Parameters stability"

Si $X - u_0 | X > u_0 \sim \text{GPD}(\tau, \epsilon)$, alors $\forall u \geq u_0$,

$$X - u | X > u \sim \text{GPD}(\bar{\tau}, \epsilon), \bar{\tau} = \tau + \epsilon(u - u_0)$$

$\Rightarrow \tau_*(u) = \bar{\tau} - \epsilon u = \tau + \epsilon(u - u_0) - \epsilon u = \tau - \epsilon u_0$.
les paramètres $\bar{\tau}$ et ϵ doivent être constants pour les seuils u valides.



lorsque le seuil u est bon, lorsque on l'augmente les résultats sont assez stables, de fait le graph. de return level est sensiblement le même.

2) Return period et return level

$$y_p = \inf \{ y \in \mathbb{R} : \bar{F}(y_p) \geq 1-p \}$$

$$\Rightarrow P(X \leq y_p) = 1-p$$

$$\Leftrightarrow P(X > y_p) = \underbrace{P(X > y_p | X > u)}_{\text{GPD}} P(X > u) = p$$

← estimé empirique

$$\Rightarrow y_p = u + \tau \frac{(P(p(u)))^{-\epsilon} - 1}{\epsilon} \quad (valeur brute)$$

↳ lorsqu'il n'y a pas u , y_p n'est qu'un excès

Interprétation: y_p est une valeur qui est dépassée une fois tous les $1/p$ observations (cela dépend de l'unité: jour, trimestre, ...). Il est possible de le mettre à une autre échelle: $1/p \cdot n_y$.

exemple: lorsque les obs. sont en jours, y_p est supposé être dépassé une fois tous les $1/p$ jours. Cependant, on peut travailler sur une échelle annuelle. Il y a $n_y = 365$ jours dans une année donc y_p est dépassé une fois tous les $1/(p \cdot n_y)$ années.

On peut interpréter la période de retour comme: "dans une période, y_p est excédé avec proba $1/\tau$ "

III - L'approche par processus ponctuel de poisson

Processus ponctuel

Un processus stochastique est une réalisation de points qui arrive aléatoirement dans un espace. On appelle mesure de comptage

$$N(A) = \sum_{i \in \mathbb{I}} \delta_{x_i}(A) = \sum_{i \in \mathbb{I}} \mathbb{I}(x_i \in A)$$

où A est un ensemble borélien et δ un dirac. On mesure mesure d'intensité

$$\Lambda: A \rightarrow \mathbb{E}[N(A)]$$

nombre moyen de points tombé dans l'espace A

Processus ponctuel de Poisson

Un processus ponctuel avec une mesure d'intensité Λ est un processus de poisson si $\forall k \geq 1$ et tous ensembles disjoints boréliens $A, A_1, \dots, A_k \in \mathcal{X}$

i) $N(A) \sim \text{Poisson}(N(A))$

ii) $N(A_1), \dots, N(A_k)$ sont des v.a indépendants.

si Λ est régulière, $N(A) = \int_A \Lambda(s) ds$
~ fonction d'intensité

Proposition:

soit $\{x_i\}$ une réalisation d'un processus de poisson sur \mathcal{X} avec une mesure d'intensité Λ . Alors
$$\mathcal{L}(x_i, \Lambda) = \exp[-\Lambda(\mathcal{X})] \prod_{i=1}^n \Lambda(x_i)$$

Théorème de

soit m_n converge vers une GEV, la séquence de processus ponctuel dans $\mathcal{X} = [0,1] \times \mathbb{R}$ (rtd)

$$\{P_m\}_{m \geq 1} = \left\{ \left(\frac{i}{m+1}, \frac{x_i - b_m}{a_m} \right) : i = 1, \dots, m \right\}$$

converge vers un PPP (μ, σ, ϵ) sur $[0,1] \times \mathbb{C}$ avec

$$\Lambda([a,b] \times [z,\infty)) = (b-a) \left(1 + \epsilon \frac{z-y}{\sigma} \right)^{-1/\epsilon}$$

où $\mathbb{C} = \{x \in \mathbb{R} : 1 + \epsilon(x-y)/\sigma > 0\}$ *

* \Rightarrow les extrêmes arrivent uniformément dans le temps.

1/ Interprétation statistique.

Dans un PPP, on travaille sur $x \geq u$. On ajuste ainsi un PPP ayant une mesure d'intensité:

$$\Lambda\{(a,b) \times (x,\infty)\} = (b-a) x \left(1 + \varepsilon \frac{x-\mu}{\sigma}\right)^{-1/\varepsilon}, \quad x \geq u, \quad (a,b) \subset [0,1]$$

Pour travailler à l'échelle annuelle,

$$\Lambda\{(a,b) \times (x,\infty)\} = n_{\text{year}} (b-a) x \left(1 + \varepsilon \frac{x-\mu}{\sigma}\right)^{-1/\varepsilon}$$

\Rightarrow le nombre d'exits ($\geq x$) dans une année en moyenne est:

$$\begin{aligned} E[N\{(0, 1/n_{\text{year}}) \times (x,\infty)\}] &= \Lambda\{(0, n_{\text{year}}^{-1}) \times (x,\infty)\} \\ &= \left(1 + \varepsilon \frac{x-\mu}{\sigma}\right)^{-1/\varepsilon} \end{aligned}$$

Le niveau y_p qui est dépassé avec proba $1/\tau$ satisfait:

$$\tau \left(1 + \varepsilon \frac{y_p - \mu}{\sigma}\right)^{-1/\varepsilon} \Leftrightarrow y_p = \mu + \sigma \frac{\tau^{-\varepsilon} - 1}{\varepsilon}$$

$\therefore y_p$ est uniquement calculé sur $x \geq u$.

IV - Cas Non Stationnaire.

En EVT, on fait l'hypothèse que x_i, y_i iid. Cependant il se peut que l'hypothèse d'indépendance (i), ou celle de la distribution identique (id) ne soient pas respectées.

Dans le contexte de série non stationnaire, i.e $E[X_t] \neq \mu$ (non constante), $\text{Var}(X_t) \neq \sigma^2$ (non constante), $\text{Cov}(X_t, X_{t+h}) = f(h)$ (non corrélation, dépend que de h), l'hypothèse id n'est pas respectée (saisonnalité, tendance)

Il existe donc trois approches :

1) Stationnarité la série (absence de saisonnalité, tendance à stabilisation de la variance)

test de nonstationnarité : Dickey Fuller / ADF
Desaisonnalisation : Differenciation, moyenne mobile

2) Restreindre le périmètre d'étude (saisons, extrêmes etc.) \rightarrow réfléchir à la construction de blocs.

3) Intégrer une saisonnalité aux paramètres GEV, GPD et PPP.

exemple $\mu(t) = \beta_0 + \beta_1 t$

on peut modéliser $\sigma(t)$ (difficile à estimer) et $\epsilon(t)$ (très difficile à estimer).

Selection de modèles

Il est possible de tester la nullité des coefficients \Rightarrow Test de Wald, rapport de vraisemblance (modèle emboîté)

test de r.v. $W = -2 \log \left(\frac{\ell(\theta_0)}{\ell(\hat{\theta})} \right) \underset{n \rightarrow \infty}{\sim} \chi^2(p)$

$\ell(\theta_0)$: modèle contraint
 $\ell(\hat{\theta})$: modèle complet
 p : nombre de contraintes.

Test de Wald $\sqrt{n}(\hat{\theta} - \theta_0) \xrightarrow[n \rightarrow \infty]{L} N(0, \sigma^2)$

dans H_0 , $\underbrace{\sqrt{n}(\hat{\theta} - \theta_0)}_{\text{attaché aux données}} \xrightarrow{\sigma} N(0, 1)$

AIC $-2\ell(\hat{\theta}) + 2p$

BIC $-2\ell(\hat{\theta}) + \log(n) \times p$ (plus parcimonieux)

asymptotiquement, l'AIC a une grande proba. de sélectionner un mauvais modèle